

Aprendizaje de una función de valor para jugar a Otelo con UCT

Fernando Pineda Muñoz
Ingeniería Informática - Ingeniería del Software
Universidad de Sevilla
Sevilla, España
ferpinmun@alum.us.es
fernaandopineda@gmail.com.es

Francisco Javier Hernández-Vaquero Garrido
Ingeniería Informática - Ingeniería del Software
Universidad de Sevilla
Sevilla, España
frahergar@alum.us.es
javaquerog05@gmail.com.es

Resumen—Este trabajo presenta el desarrollo de un agente inteligente para el juego de Otelo mediante la combinación de Monte Carlo Tree Search, la regla UCT y una red neuronal de valor. El objetivo es obtener un jugador capaz de seleccionar movimientos competitivos sin usar una heurística manual como evaluador principal.

La implementación incluye el motor completo del juego, varios agentes de referencia, generación de datos por auto-juego, entrenamiento supervisado de una red neuronal y una batería de experimentos entre jugadores. En los experimentos realizados, UCT con 16 iteraciones supera a un jugador voraz por 8 victorias a 4 y el agente UCT con red neuronal mejora ese resultado, ganando 9 partidas de 12 frente al mismo rival. Además, UCTNN-16 supera a UCT-16 por 10 victorias a 2 en el torneo ejecutado.

Palabras clave—Otelo, Reversi, búsqueda adversaria, Monte Carlo Tree Search, UCT, redes neuronales, aprendizaje supervisado.

I. Introducción

Otelo, también conocido como Reversi, es un juego determinista, de suma cero y con información perfecta. Estas propiedades lo convierten en un dominio adecuado para estudiar técnicas de búsqueda adversaria y aprendizaje automático. Aunque el espacio de estados de Otelo es menor que el de Go, sigue siendo demasiado grande para resolverlo exhaustivamente durante una partida real.

El objetivo del trabajo es implementar un agente basado en Monte Carlo Tree Search (MCTS) con selección Upper Confidence bounds applied to Trees (UCT). La versión básica usa simulaciones aleatorias como política por defecto, mientras que la versión avanzada reemplaza dicha política por una red neuronal que estima el valor de una posición. Este planteamiento sigue de forma simplificada la idea general de combinar búsqueda y aprendizaje que aparece en AlphaGo y AlphaZero [3], [4].

El interés del problema no está solo en obtener un programa capaz de jugar, sino en estudiar cómo se pueden combinar dos familias de técnicas vistas en la asignatura. Por un lado, la búsqueda adversaria permite razonar explícitamente sobre las consecuencias de las acciones disponibles. Por otro lado, el aprendizaje automático permite construir una función de evaluación a partir de datos, evitando diseñar manualmente todos los criterios

estratégicos del juego. En este trabajo se ha mantenido una separación clara entre ambos componentes: el algoritmo UCT es responsable de explorar alternativas, mientras que la red neuronal proporciona una estimación rápida del valor de los estados.

La implementación se ha desarrollado buscando tres objetivos prácticos. El primero es la corrección de las reglas, porque cualquier error en la generación de movimientos invalidaría tanto el entrenamiento como los torneos. El segundo es la reproducibilidad: todos los experimentos se pueden lanzar mediante comandos de consola con semillas fijas y los resultados quedan guardados en ficheros estructurados. El tercero es la facilidad de defensa, de modo que cada módulo del código tenga una responsabilidad concreta y pueda explicarse de forma independiente.

El documento se organiza de la siguiente forma. En la sección de preliminares se describen las reglas de Otelo, MCTS, UCT y la red neuronal de valor. La sección de implementación detalla la estructura del código y las decisiones de diseño. La sección de pruebas y experimentación presenta el procedimiento seguido para generar datos, entrenar el modelo y comparar agentes. Finalmente, se resumen las conclusiones y las principales líneas de mejora.

II. Preliminares

A. Reglas y representación

El tablero se representa como una matriz de tamaño 8×8 . Internamente se usa 1 para negras, -1 para blancas y 0 para casillas vacías. Para el dataset se puede exportar también la codificación del enunciado: 0 vacía, 1 blanca y 2 negra.

Un movimiento es legal si coloca una ficha en una casilla vacía y captura al menos una ficha rival en dirección horizontal, vertical o diagonal. Si un jugador no tiene movimientos legales debe pasar. La partida termina cuando el tablero está lleno o cuando ambos jugadores no tienen movimientos legales.

La implementación comprueba las ocho direcciones posibles desde la casilla candidata. En cada dirección se exige encontrar primero una o más fichas rivales y, a continuación, una ficha propia que cierre la línea. Solo

entonces las fichas intermedias se consideran capturadas. Esta comprobación se usa tanto para determinar los movimientos legales como para aplicar una jugada, lo que reduce la posibilidad de inconsistencias entre ambas operaciones.

Para entrenar la red no se usa directamente la matriz con valores 1, -1 y 0. En su lugar, cada posición se transforma a una representación desde la perspectiva del jugador activo. Los primeros 64 atributos indican qué casillas contienen fichas propias y los 64 restantes indican qué casillas contienen fichas rivales. Esta codificación evita que la red tenga que aprender dos casos separados para blancas y negras, porque siempre interpreta la entrada desde el punto de vista del jugador al que le toca mover.

B. Monte Carlo Tree Search y UCT

MCTS construye un árbol de búsqueda de manera incremental. Cada iteración contiene cuatro fases: selección, expansión, simulación y retropropagación. En la fase de selección se emplea UCT para equilibrar explotación y exploración:

$$UCT(s, a) = Q(s, a) + c \sqrt{\frac{\ln N(s)}{N(s, a)}}. \quad (1)$$

En esta implementación se usa una versión negamax. Cada nodo almacena el valor medio desde la perspectiva del jugador que debe mover en ese nodo. Por tanto, cuando el padre selecciona un hijo, interpreta el valor del hijo con signo opuesto.

La fase de selección recorre el árbol escogiendo en cada nodo el hijo con mayor valor UCT. El primer término, $Q(s, a)$, representa el valor medio observado al escoger la acción a desde el estado s . El segundo término aumenta el atractivo de acciones poco visitadas y depende de $N(s)$, el número de visitas del nodo padre, y $N(s, a)$, el número de visitas del hijo. La constante c controla el equilibrio entre explotación y exploración; se ha usado el valor $\sqrt{2}$, habitual como punto de partida.

La política por defecto de MCTS es especialmente importante. En la versión clásica, cuando se alcanza un nodo nuevo, se juega una partida simulada hasta el final mediante decisiones aleatorias. El resultado de esa simulación se retropropaga por el árbol. En Otebo estas simulaciones son relativamente baratas, pero siguen consumiendo tiempo y pueden producir estimaciones ruidosas. Por ello la versión con red neuronal sustituye la simulación completa por una predicción del valor del estado.

C. Red neuronal de valor

La red neuronal resuelve una tarea de regresión supervisada. La entrada contiene 128 atributos: un canal binario para las fichas propias y otro canal binario para las fichas rivales. La salida es un número real en $[-1, 1]$, obtenido con una activación tanh. El valor objetivo es +1 si el jugador activo en ese estado ganó la partida, 0 si empató y -1 si perdió.




Fig. 1. Fases principales de una iteración de MCTS con UCT.




Fig. 2. Esquema de la red neuronal de valor utilizada.

Aunque el enunciado menciona herramientas como TensorFlow, la red se ha implementado con NumPy para mantener el proyecto ligero y completamente ejecutable en el entorno disponible. La arquitectura usada en el experimento final tiene dos capas ocultas densas de 64 y 32 neuronas, activación ReLU en las capas ocultas y activación tanh en la salida. El entrenamiento usa error cuadrático medio y descenso de gradiente por mini-lotes mediante retropropagación.

TABLA I
Arquitectura de la red de valor.

Capa	Tamaño	Activación
Entrada	128	–
Oculto 1	64	ReLU
Oculto 2	32	ReLU
Salida	1	tanh

El valor predicho no debe interpretarse como una probabilidad calibrada en sentido estadístico estricto, sino como una estimación normalizada de ventaja para el jugador activo. Valores cercanos a 1 indican posiciones que la red considera favorables, valores cercanos a -1 posiciones desfavorables y valores próximos a 0 posiciones equilibradas o inciertas.

D. Trabajo relacionado

La búsqueda adversaria clásica, incluyendo minimax y poda alfa-beta, se estudia habitualmente como punto

de partida para juegos deterministas de dos jugadores con información perfecta [1]. Estos métodos exploran el árbol de juego de manera sistemática, pero necesitan funciones heurísticas cuando no es posible llegar hasta estados terminales. En Othello, como en ajedrez o Go, la profundidad completa de la partida hace inviable una expansión exhaustiva en tiempo real.

MCTS ofrece una alternativa más flexible porque concentra el esfuerzo en las ramas que parecen más prometedoras según la experiencia acumulada durante las simulaciones. El artículo de Browne et al. [2] resume variantes de MCTS y presenta UCT como una forma efectiva de resolver el dilema entre explorar acciones poco probadas y explotar acciones con buenos resultados previos. Esta idea encaja bien con juegos como Othello, donde el factor de ramificación cambia mucho a lo largo de la partida.

Los trabajos de AlphaGo y AlphaZero muestran que las redes neuronales pueden mejorar la búsqueda cuando aprenden a evaluar posiciones o a priorizar movimientos [3], [4]. La propuesta desarrollada aquí no pretende reproducir esos sistemas, que usan arquitecturas profundas, grandes cantidades de cómputo y entrenamiento iterativo. La contribución de este trabajo es una versión reducida y explicable: UCT proporciona la búsqueda y una red de valor sencilla sustituye la simulación aleatoria de la política por defecto.

III. Implementación

El proyecto se organiza como un paquete Python. El módulo `game.py` implementa las reglas, `mcts.py` implementa UCT, `agents.py` define los jugadores, `self_play.py` genera datasets, `neural.py` define la red de valor, `train.py` lanza el entrenamiento a partir de un dataset guardado y `tournament.py` ejecuta comparativas.

A. Motor del juego

El motor del juego se implementa en la clase `OthelloState`. Cada estado contiene el tablero, el jugador activo y el número de pases consecutivos. Esta última variable permite detectar correctamente el final de la partida cuando ambos jugadores pasan. Los estados se tratan como objetos inmutables: al aplicar una jugada se crea un nuevo estado con un tablero copiado. Esta decisión aumenta el coste de memoria, pero simplifica la búsqueda porque los nodos del árbol no comparten tableros modificables.

El módulo también incluye funciones auxiliares para convertir coordenadas de texto, calcular puntuaciones, representar el tablero en ASCII y obtener características para la red. La interfaz de texto muestra con asteriscos las jugadas legales, lo que permite probar el agente sin necesidad de construir una interfaz gráfica.

B. Agentes implementados

Se han implementado varios agentes para disponer de rivales de dificultad creciente. El agente aleatorio elige

uniformemente una acción legal y sirve como baseline mínimo. El agente voraz selecciona la jugada que voltea más fichas en el movimiento inmediato. El agente heurístico combina diferencia de fichas, movilidad y esquinas. Finalmente, los agentes UCT y UCTNN usan búsqueda de árbol con la diferencia de que UCTNN recibe una red neuronal entrenada como evaluador.

Disponer de estos agentes facilita el análisis experimental. Si el agente UCT no superase al aleatorio o al voraz, probablemente habría un error en la búsqueda o en las reglas. Si UCTNN no mejorase a los baselines, la causa podría estar en la calidad del dataset, en la arquitectura de la red o en la integración con MCTS.

El agente heurístico no forma parte del requisito principal de junio, pero se incluyó para disponer de una referencia intermedia entre el agente voraz y UCT. Su evaluación combina tres criterios. La diferencia de fichas mide la ventaja material actual; la movilidad mide cuántas acciones legales conserva cada jugador; y las esquinas capturan un aspecto estratégico importante, ya que una ficha situada en una esquina no puede ser volteada posteriormente. La ponderación usada no se ha optimizado automáticamente, sino que se ha elegido como una heurística simple y explicable.

Esta variedad de agentes también permite detectar comportamientos anómalos. Por ejemplo, un agente que gana al aleatorio pero pierde claramente contra el voraz puede estar tomando decisiones localmente razonables pero estratégicamente débiles. Un agente que mejora al voraz pero no escala al aumentar iteraciones puede estar limitado por la política por defecto. Estas comparaciones son importantes porque una única partida aislada no permite evaluar de forma fiable la calidad de un jugador.

C. Integración de la red en UCT

La integración se realiza mediante un parámetro evaluador en la clase `UCTSearch`. Si este parámetro es nulo, la evaluación de un nodo no terminal se obtiene mediante la política por defecto, que realiza una simulación hasta el final de la partida o hasta un límite de profundidad. Si el parámetro contiene una función, UCT llama directamente a esa función y limita el resultado al intervalo $[-1, 1]$. El agente UCTNN pasa como evaluador una llamada a `network.predict_state`.

Esta decisión evita duplicar el código de MCTS: el mismo algoritmo sirve para la versión clásica y para la versión neuronal. La diferencia de comportamiento queda localizada en la función de evaluación, que es precisamente el punto que pide modificar el enunciado de la convocatoria de junio.

La política por defecto de la versión básica realiza una simulación aleatoria hasta final de partida. La versión con red neuronal sustituye esa simulación por una llamada al modelo de valor, reduciendo el coste de evaluación y guiando la búsqueda hacia posiciones aprendidas mediante autojuego.

UCT(*estado, iters*)

Entrada: estado actual del juego

- 1 Salida: movimiento seleccionado
- 2 $raiz \leftarrow$ nuevo nodo con estado
- 3 repetir *iters* veces
- 4 $nodo \leftarrow$ selección(*raiz*)
- 5 si nodo no es terminal entonces
- 6 $nodo \leftarrow$ expandir(*nodo*)
- 7 $valor \leftarrow$ eval(*nodo.estado*)
- 8 backprop(*nodo, valor*)
- 9 devolver mejor hijo de raiz

Fig. 3. Esquema del algoritmo UCT implementado.

D. Generación de datos

El dataset se genera mediante partidas automáticas entre dos copias del mismo agente. Durante cada partida se guardan los estados intermedios después de cada movimiento. Al finalizar, cada estado recibe como etiqueta el resultado de la partida desde la perspectiva del jugador activo en ese estado. De esta forma, el mismo tablero puede tener interpretaciones distintas si cambia el jugador al que le toca mover.

Para aumentar el número de ejemplos se aplican las ocho simetrías del tablero: cuatro rotaciones y sus reflejos horizontales. Estas transformaciones conservan el resultado estratégico de la posición, por lo que permiten aumentar el dataset sin generar nuevas partidas. En el experimento final, 50 partidas de autojuego produjeron 23792 ejemplos tras aplicar estas simetrías.

E. Entrenamiento de la red

El entrenamiento se separa en dos niveles. El módulo neural.py contiene la implementación de la red neuronal, incluyendo propagación hacia delante, cálculo de la pérdida, retropropagación y guardado/carga de pesos. El módulo train.py actúa como punto de entrada desde consola: carga el archivo npz generado por autojuego, construye una ValueNetwork con las capas indicadas por argumentos, ejecuta el entrenamiento durante el número de épocas elegido y guarda el modelo entrenado en models/.

Esta separación permite reutilizar la red desde otros módulos sin repetir código de entrenamiento. Por ejemplo, experiments.py usa directamente ValueNetwork para automatizar todo el pipeline, mientras que train.py permite entrenar manualmente un modelo concreto cambiando parámetros como capas ocultas, tasa de aprendizaje, tamaño de lote o número de épocas.

F. Reproducibilidad

Los experimentos se agrupan en el módulo experiments.py. Este script genera el dataset, entrena la red, ejecuta los torneos y escribe los resultados en formato Markdown y JSON. Además, todas las llamadas usan

semillas configurables. Esto permite repetir la misma ejecución durante la defensa o modificar fácilmente el número de partidas, épocas o iteraciones UCT.

TABLA II
Artefactos principales generados por el proyecto.

Fichero	Contenido
selfplay_experiment.npz	Dataset de estados y etiquetas
value_net_experiment.npz	Pesos de la red entrenada
experiment_results.md	Resumen legible de torneos
experiment_results.json	Resultados estructurados
memoria-otelo.pdf	Documento final compilado

Los ficheros npz se han elegido porque permiten almacenar varios arrays NumPy comprimidos en un único archivo. El dataset contiene los atributos x, las etiquetas y y metadatos sobre el agente usado para el autojuego. El modelo contiene el tamaño de entrada, las capas ocultas y las matrices de pesos y sesgos de cada capa. Esta separación permite regenerar el modelo desde cero o reutilizar uno ya entrenado en torneos posteriores.

G. Coste computacional

El coste de una decisión UCT depende principalmente del número de iteraciones y del coste de evaluar cada nodo expandido. En la versión básica, cada evaluación puede implicar una simulación completa de partida. Aunque Oteló tiene un tablero pequeño, una simulación puede contener decenas de movimientos y cada movimiento requiere volver a calcular acciones legales. Por ello, aumentar el número de iteraciones mejora la calidad de la búsqueda, pero también incrementa rápidamente el tiempo por jugada.

La versión neuronal modifica este equilibrio. Evaluar una posición con la red consiste en varias multiplicaciones matriciales pequeñas: 128×64 , 64×32 y 32×1 . Este coste es mucho más estable que una simulación aleatoria completa. La desventaja es que la evaluación deja de ser una muestra directa del resultado de una partida y pasa a depender de la calidad del entrenamiento. En otras palabras, UCT básico suele ser más caro pero menos sesgado por el dataset; UCTNN es más rápido, pero puede




Fig. 4. Flujo completo de generación de datos, entrenamiento y uso del modelo.

equivocarse sistemáticamente si la red ha aprendido mal ciertas posiciones.

TABLA III

Comparación cualitativa de evaluadores dentro de UCT.

Evaluador	Ventaja	Riesgo
Rollout	No requiere datos	Coste alto y ruido
Heurística	Muy rápido	Diseño manual
Red valor	Rápido y aprendido	Depende del dataset

En los resultados obtenidos se aprecia esta diferencia. El torneo UCT-16 contra Greedy tardó 36.4 segundos, mientras que UCTNN-16 contra Greedy tardó 2.5 segundos. La comparación no mide solo una jugada, pero sí muestra que sustituir rollouts por una red reduce mucho el tiempo total de juego. La cuestión abierta es mejorar la calidad del evaluador neuronal para que esa ganancia de velocidad no implique perder fuerza de juego.

IV. Pruebas y experimentación

Se han preparado pruebas unitarias para verificar los movimientos legales iniciales, el volteo de fichas, la obligación de pasar, la detección de final de partida y la integración básica de UCT. Estas pruebas se ejecutan con:

```
python3 -m unittest discover -s tests -v
```

En la ejecución realizada se superaron 8 pruebas unitarias. Estas pruebas no demuestran que el agente sea óptimo, pero sí reducen el riesgo de fallos básicos en el motor: movimientos iniciales incorrectos, volteos mal aplicados, pases ilegales o partidas que no terminan. También se verifica que UCT siempre devuelve una acción legal en el estado inicial y que la red puede realizar al menos una iteración de entrenamiento.

A. Diseño experimental

Los torneos alternan el color inicial entre agentes para reducir el sesgo de que negras muevan primero. La medida principal es el número de victorias, derrotas y empates. Como medida secundaria se usa la diferencia media de fichas desde la perspectiva del agente A, porque permite distinguir victorias ajustadas de victorias amplias. También se registra el tiempo total de cada torneo para comparar el coste de los distintos evaluadores.

El experimento reproducible se ejecutó con el siguiente comando:

```
python3 -m othello_ai.experiments \
--selfplay-games 50 \
--selfplay-agent uct:12 \
--epochs 35 \
```

```
--tournament-games 12 \
--uct-iters 16 \
--seed 23
```

La configuración se eligió como compromiso entre tiempo de ejecución y capacidad de obtener resultados interpretables en un entorno local. Frente a una primera prueba con 12 partidas, se aumentó el autojuego a 50 partidas para que la red recibiera posiciones más variadas. Los resultados siguen sin ser una estimación definitiva de fuerza de juego, pero ya permiten valorar mejor el efecto de usar una función de valor aprendida.

TABLA IV

Configuración y resultado del entrenamiento.

Magnitud	Valor
Partidas de autojuego	50
Agente de autojuego	UCT-12
Ejemplos generados	23792
Capas ocultas	64, 32
Épocas	35
Loss entrenamiento	0.79606
Loss validación	0.80524

El conjunto de entrenamiento se generó por autojuego usando UCT con 12 iteraciones por decisión. Cada estado intermedio se etiquetó con el resultado final desde la perspectiva del jugador activo y se aplicaron las ocho simetrías del tablero. La pérdida de validación bajó de 0.91996 a 0.80524, lo que indica que la red aprende una señal útil y mejora claramente respecto a la prueba inicial con menos partidas.

La tabla V muestra tres conclusiones principales. En primer lugar, las heurísticas simples ya son claramente superiores al jugador aleatorio, por lo que son buenos rivales de control. En segundo lugar, UCT mejora al jugador voraz incluso con solo 16 iteraciones, y aumentar a 32 iteraciones produce una mejora frente a UCT-16. En tercer lugar, UCTNN-16 obtiene los mejores resultados del experimento ampliado: gana 11 partidas y empata una contra Random, supera 9-3 a Greedy y vence 10-2 a UCT-16. Este cambio respecto a la prueba inicial muestra que aumentar el dataset tuvo un efecto positivo en la utilidad de la red.

También se observa una diferencia clara de coste temporal. El torneo UCT-16 contra Greedy tardó 36.4 segundos, mientras que el torneo UCTNN-16 contra Greedy tardó 2.5 segundos. Esta diferencia aparece porque la red sustituye las simulaciones aleatorias completas de la política por defecto por una evaluación directa del estado.

TABLA V
Resultados de los torneos. La diferencia media se mide desde la perspectiva del agente A.

Agente A	Agente B	Partidas	Victorias A	Victorias B	Empates	Dif. media A
Greedy	Random	12	9	3	0	8.83
Heurístico	Greedy	12	11	1	0	24.92
UCT-16	Greedy	12	8	4	0	6.00
UCT-32	UCT-16	12	7	4	1	9.33
UCTNN-16	Random	12	11	0	1	17.33
UCTNN-16	Greedy	12	9	3	0	9.50
UCTNN-16	UCT-16	12	10	2	0	13.33

B. Análisis de errores y limitaciones

El resultado más importante desde el punto de vista crítico es que UCTNN-16 mejora claramente tras ampliar el dataset. En la prueba inicial, entrenada con solo 12 partidas, no superaba al agente voraz. Con 50 partidas de autójuego y 23792 ejemplos tras simetrías, el mismo enfoque vence a Greedy y a UCT-16. Esto apoya la hipótesis de que la función de valor aprendida depende mucho de la cantidad y variedad de estados usados durante el entrenamiento.

Otra limitación es que la red predice solo el valor del estado, no una política de movimientos. Esto significa que UCTNN sigue expandiendo acciones sin una guía neuronal directa sobre qué jugadas son más prometedoras. En sistemas como AlphaZero se aprenden simultáneamente una política y una función de valor, lo que permite dirigir mucho mejor la búsqueda. En este trabajo se ha mantenido una versión más sencilla porque el objetivo de la convocatoria es reemplazar la política por defecto de UCT por una red de evaluación.

Por último, el número de partidas de torneo es bajo. Doce partidas por emparejamiento permiten observar tendencias, pero no proporcionan una estimación estadística estable. Para una evaluación más fuerte sería conveniente repetir los torneos con al menos 50 o 100 partidas por enfrentamiento y varias semillas distintas.

C. Amenazas a la validez

La primera amenaza a la validez interna es la aleatoriedad. MCTS, los agentes aleatorios y la inicialización de la red dependen de semillas. Aunque los experimentos fijan una semilla para poder reproducir los resultados, otras semillas podrían producir variaciones, especialmente con tan pocas partidas. Por ese motivo, las conclusiones se formulan como tendencias observadas y no como afirmaciones absolutas sobre la fuerza de cada agente.

La segunda amenaza es el sesgo del generador de datos. Como el autójuego se realizó con un agente UCT pequeño, las posiciones del dataset reflejan el estilo de juego y los errores de ese agente. Si se generasen partidas con más iteraciones, con varios tipos de rivales o mediante reentrenamiento iterativo, la red probablemente recibiría ejemplos más variados y podría mejorar su capacidad de generalización.

La tercera amenaza es la escala del entrenamiento. Aunque el dataset ampliado es más razonable que el inicial, sigue siendo pequeño comparado con los enfoques de aprendizaje por autójuego a gran escala. Esta decisión fue adecuada para mantener el proyecto ejecutable en un ordenador personal, pero limita la calidad máxima del evaluador neuronal. Aún así, el experimento es suficiente para comprobar el requisito principal de la convocatoria: diseñar una red, entrenarla con estados de Oteló y usarla dentro de MCTS como reemplazo de la política por defecto.

D. Uso durante la defensa

El proyecto está preparado para poder mostrar tres tipos de ejecución durante la defensa. La primera es una partida interactiva contra la máquina usando la interfaz de texto. Esta ejecución permite comprobar que el motor aplica las reglas correctamente y que el agente devuelve movimientos legales. La segunda es un torneo corto entre dos agentes, útil para mostrar cómo se comparan los jugadores sin intervención humana. La tercera es la ejecución del script de experimentos, que reproduce el pipeline completo de generación de datos, entrenamiento y evaluación.

Estas ejecuciones también ayudan a responder preguntas técnicas. Si se pregunta dónde se sustituye la política por defecto, la respuesta está en el parámetro evaluador de UCT. Si se pregunta qué contiene el modelo, se puede mostrar que el archivo guarda únicamente matrices de pesos y vectores de sesgos. Si se pregunta cómo se etiqueta un estado, se puede explicar que la etiqueta se asigna al finalizar la partida, según el resultado desde la perspectiva del jugador activo en ese estado.

Una modificación sencilla que podría pedirse en directo es cambiar el número de iteraciones de UCT o enfrentar otros agentes. El diseño por argumentos de línea de comandos permite hacerlo sin tocar el código. Otra modificación posible es entrenar una red con más épocas o con otro tamaño de capas ocultas. Estos parámetros también están expuestos en los scripts, de modo que el trabajo no depende de valores fijados de forma rígida en el código.

V. Conclusiones

El proyecto implementa el pipeline completo solicitado para la convocatoria de junio: reglas de Otelo, UCT, generación de estados por autojuego, entrenamiento de una red neuronal y uso de esa red como evaluador dentro de la búsqueda. La principal ventaja del enfoque es que separa claramente el motor del juego, la búsqueda y el aprendizaje, lo que facilita la defensa y la realización de experimentos.

Los resultados muestran que UCT es una mejora sólida sobre los baselines simples y que la red neuronal aprende una función de valor con información útil. Con el dataset ampliado, el agente UCTNN-16 supera a Random, Greedy y UCT-16 en los torneos realizados. La interpretación más plausible es que aumentar la cantidad de autojuego mejora la calidad del evaluador neuronal y permite que la red aporte una ventaja real dentro de MCTS.

Como trabajo futuro se propone aumentar el número de partidas de entrenamiento, comparar distintas arquitecturas de red, ajustar la constante de exploración de UCT y realizar reentrenamiento iterativo. También sería posible aprender una política de movimientos además de la función de valor, acercando el sistema a los enfoques usados en AlphaZero.

Referencias

- [1] S. Russell and P. Norvig, *Artificial Intelligence: A Modern Approach*, 4th ed. Pearson, 2020.
- [2] C. B. Browne et al., “A survey of Monte Carlo Tree Search methods,” *IEEE Transactions on Computational Intelligence and AI in Games*, vol. 4, no. 1, pp. 1–43, 2012.
- [3] D. Silver et al., “Mastering the game of Go with deep neural networks and tree search,” *Nature*, vol. 529, pp. 484–489, 2016.
- [4] D. Silver et al., “Mastering Chess and Shogi by self-play with a general reinforcement learning algorithm,” *arXiv:1712.01815*, 2017.